向量数据库顾名思义，首先是个数据库，库里存放的是什么呢，是向量，是什么向量，是文本的表征向量，是利用向量化大模型将文本表征为向量，怎么把向量存储到数据库里呢？

首先选择使用的数据库如 faiss，然后数据库会给向量添加标签，如从 0 开始顺序编号。

问题

问题 1：向量化的文本大小是多大，如何定义？
向量化是如何完成的，句子向量化和词元向量化的对比？
向量化之后得到的向量数据格式是什么样的
faiss 普通的添加标签是如何添加的？为啥需要知道向量的维度？
添加标签有什么改进方法？对向量本身有操作吗有影响吗？
对索引的训练变化的到底是什么，是利用向量进行训练，向量组织形式进行变化，那索引是如何变化的？
添加完标签就是创建了一个向量数据库吗？
怎么对向量数据库进行存储，加载？
如果增加文本向量，怎么增加向量数据库？
如果对同一文本进行重新向量化，数据库又该如何变化？
单独加载索引 index 和缓存池加载索引的异同点？索引存储的路径和方式？
单独加载和基于 langchain 框架下的加载方式的比较？
Faiss 对象对向量和元数据的操作方法与手动管理 faiss 索引元数据的方法的对比分析

Faiss 和嵌入模型的关系

Faiss 对象从 faisspool 获取，继承 cachepool 的 load_kb_embedding 方法，faiss 对象继承的该方法加载嵌入模型有 2 种方式，

一种是在线模型，调用 kbservice 里的 embeddingfunadapter 类（业务层面），然后 embeddingfunadapter 调用后端 embedding-api 的实际实现方法 embed_texts 方法（但是这里的方法内部又区分了一次在线模型和本地模型），在线模型直接调用 worker 实现；本地模型又嵌套一层 server.utils 里的 load_local_embedding 方法，而这个方法也是调用了 embedding_pool 的 load_embedding 方法。

二是本地模型，调用 embedding_pool 的 load_embedding 方法。

向量化处理与向量数据库

向量化：句子级 vs 词元级 Token

词元 Token 级向量化

方法：模型处理单个词或子词（如 BERT 的 WordPiece）。
输入：句子被拆分为多个 token（如 ["The", "Apollo", "program", ...]）。
输出：每个 token 生成 1 个向量（形状为 (seq_length, d_model)）。
特点：细粒度语义，但需额外处理（如池化）才能用于检索。

句子级向量化

方法：使用预训练模型（如 all-MiniLM-L6-v2）对整个句子进行编码。
输入：完整句子（如 "The Apollo program..."）。
输出：每个句子生成 **1 个** 固定长度的向量（如 384 维）。
特点：保留句子整体语义，适合段落检索。

RAG 中通常使用句子级向量化，因检索目标是段落或文档块。句子向量化（如 all-MiniLM-L6-v2）和 token 向量化（如 BERT 的 WordPiece）的区别是：句子向量化是先把每一个 token 计算得到一个向量，然后池化得到整个句子的向量，这也是为什么句子级向量化加载模型的时候会同步加载一个池化模型，具体步骤为：

对每个句子进行分词 → 生成 token 向量 → 通过池化（平均或 CLS）合并为句子向量。

FAISS 的本质-向量和索引

向量库的本质是将文本转换成的向量存储到索引结构，然后存储到 index 索引文件，类似于原来的文本存储到 docx，xls，pdf 等类型文件里，索引结构通过分块，量化，图结构提供了高效的近似性检索以及存储能力，不是匹配文本而是匹配向量相似度。因此向量库就是一个高效的基于向量相似度的搜索引擎，向量库本身可以理解为文档内容的另一种存储形式。

向量库是一个存储高维向量的数据库，高维向量对应的是提取编码的分割后的文本、提取的图片音视频内容等的向量特征表示（不关心**对应的原始内容是什么**），可以用来快速检索向量库中与查询向量（同样的嵌入模型编码）最相似的 top-k 向量。

FAISS 是最常用的一个向量库，下面基于此进行介绍。

那么 faiss 等向量库到底是如何存储向量的呢？或者说这些向量存储到哪里了呢？

先来看一下向量自身的数据结构，向量本身是一个二维数组，每一行代表一个句子的向量，行数代表句子的数量。每一行的行号就是向量的逻辑 id（从 0 开始），经嵌入模型生成后，无论向量物理结构和存储地址如何变化，向量的逻辑 id 就不再变化，

而为了提高检索能力，向量库提供特殊的数据结构——索引（现在可简单类比列表或字典等，后面会详细介绍），来存储每一行向量。存储分为 2 个步骤，一是在训练和创建过程中，会把向量存储到索引结构里，二是会把索引结构写入到索引文件里（类比把文本写入到 word 里）。索引会有一个属性 ntotal 记录当前索引中存储的向量总数；

因为 faiss 向量库存储检索返回的都是向量，但在 RAG 等实际应用中，需要对应的原始数据，因此，向量库需要设置一个额外的存储结构，用以存储高维向量和原始数据的对应关系。在基本使用时，需要手动维护一个字典，保存向量 id（键）和原始数据（值），在 langchain 框架下，自带了一个 docstore 自动维护。

在实际 RAG 项目中，我们可以发现向量化的一般是分割后的文本，但 faiss 库中保存文档内容的名字却叫 docstore，这是因为：

1.术语通用性

document 在信息检索（IR）领域是**标准术语**，指代被检索的最小单元（无论其形式是文本、图片元数据等）。FAISS 作为通用向量引擎，使用 doc 保持领域一致性。并非意味着存储的是完整 "document"。

2.内容无关性

存储的内容可能是：文本片段（Text Chunk）或 图片的描述信息 或 结构化数据的 JSON 片段，docstore 的命名**不限定内容类型**，比 textstore 更灵活。

概念辨析

向量：一个句子一个向量表示，多个句子组成二维数组

逻辑 ID：最原始就是向量的行数（从 0 开始计数），可以映射为自定义 ID（和原始 ID 数组对应）

索引结构：向量的组织形式，普通数组，倒排，量化，图索引

langchain 下的 ID：本质是将自定义 ID（整数）改为 uuid，仍和原始位置 id 对应，同时建立了 uuid 和文本的字典对应

FAISS 构建向量库的基本步骤

第一步 文本向量化
# 加载嵌入模型
model = SentenceTransformer('all-MiniLM-L6-v2') # 句子级编码模型
# 生成向量并获取向量维度
embeddings = model.encode(texts) # 输入 4 个句子，输出形状 (4, 384)
dimension = embeddings.shape[1] # 384，这一步是获取向量的维度，因为存储时需要根据维度大小分配空间，若某向量维度不符合，则报错。
# 第二步 创建 id 和文本的映射关系字典 docstore
docstore = {} # 文档存储：向量 ID -> 原始内容
#原始文本存入 docstore
for id,text in enumerate(texts):
    docstore[id] = text
# 第三步 索引添加向量
# 创建索引
index = faiss.IndexFlatL2(dimension) # 初始化索引结构，按照顺序赋予 0,1,2 标签
#索引添加向量
index.add(embeddings) # 将向量添加到索引

在添加数据前后，索引对象的内存地址不会变化，**索引对象本身是同一个**：add 操作只是将向量数据添加到这个预先创建好的索引结构中，并没有创建一个新的索引对象。

#保存索引
faiss.write_index(index, "knowledge_base.index") # 其中 index 是待写的索引内容，knowledge_base.index 是待要写入的索引文件名称（类比 docx 等文档内容写入）

#加载索引
index = faiss.read_index("index_file.index")#参数为文件路径，类比 docx 等文档内容读取
#检索问题向量化
query_vector = embed("问题文本")
#计算距离，返回相似向量 ids
distances, ids = index.search(query_vector, k=5)
根据搜索得到的 id 返回对应的文本：
results = [docstore[id] for id in ids[0]] #通过 docstore 找回原始文本

FAISS 索引类型和对应的向量存储形式

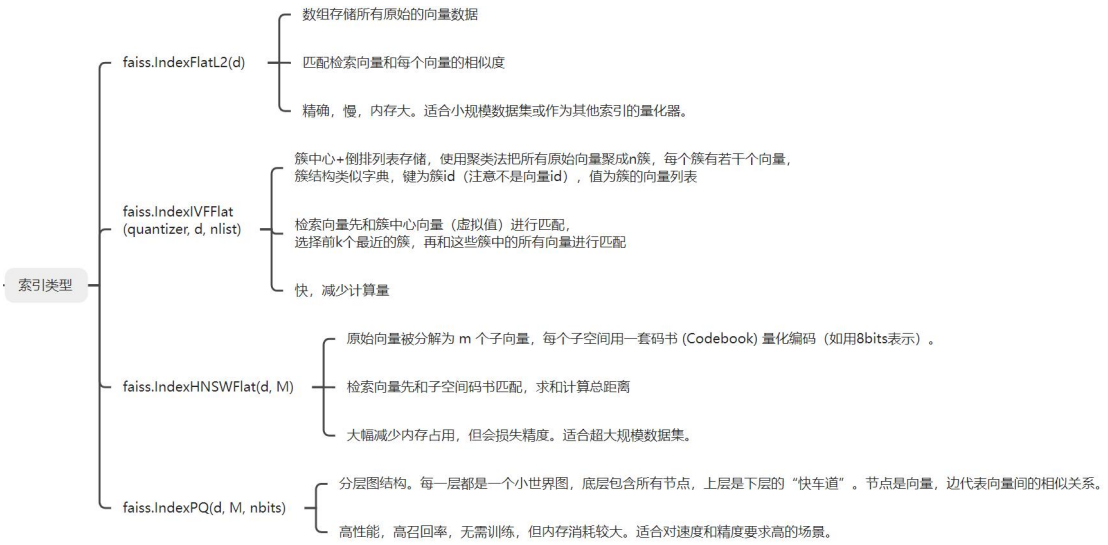

IndexFlatL2

是一个连续数组，存储所有的原始向量数据（可以类比列表），因此索引 id 隐式从 0 开始按照顺序增加，对应原始向量的行下标。
输入数据
vectors = [
[0.1, 0.2, 0.3, 0.4], # ID=0
[0.5, 0.6, 0.7, 0.8], # ID=1
[0.9, 1.0, 1.1, 1.2] # ID=2
]
IndexFlatL2 索引
 # 内存中的二维数组（float32）
index= [
[0.1, 0.2, 0.3, 0.4],
[0.5, 0.6, 0.7, 0.8],
[0.9, 1.0, 1.1, 1.2]]

```
# 使用 reconstruct() 方法输出特定位置的向量
# 语法：reconstruct(vector_id)
vector_id_to_fetch = 2  # 我们想获取索引中第 3 个向量（索引从 0 开始）
reconstructed_vector = index.reconstruct(vector_id_to_fetch)
```

IndexFlatL2 这种索引结构，在向量搜索时采用暴力搜索，会计算查询向量和所有向量的相似度，时间复杂度较高，速度慢，内存占用大，用于**精确搜索**。适合**小规模数据集**或作为其他索引的量化器。

改进方向从聚类和图结构两方面考虑。

聚类法和倒排索引 IndexIVFFlat

聚类法是将**文本的向量**分组聚类，相当于先进行预训练把相似的向量放到一起，**核心步骤如下：**

聚类训练：用 K-means 算法将全体向量划分为 nlist 个簇，得到簇中心点。这里的簇中心点是先随机选择一个向量，然后计算划到该簇的向量的平均值作为质心，不断迭代直至收敛；

向量分配：将每个向量分配到距离最近的簇中心对应的簇中，每个簇以列表的形式存储划分过来的向量。

倒排索引：建立簇 ID （非簇中心向量）→ 向量列表的映射关系，形成倒排索引表。

```
# 训练聚类器（K-means 过程）
assert not index.is_trained
index.train(data)
# 输出：训练耗时和收敛情况
assert index.is_trained
```

这时我们再看一下向量和索引是如何变化的？

向量分配到各个簇后，此时**物理存储结构会变，但是逻辑 id 不变，搜索时返回的也是这个逻辑 id**。

索引结构存储了 nlist 个簇中心向量，每个中心向量对应一个列表，里面存储该簇的向量（可以类比为字典，簇 id 为键，簇向量列表为值）

检索优化：搜索时先计算查询向量与所有簇中心向量的距离，然后选出最近的前 **nprobe 个簇**，再从选出的簇向量进行二次计算，大幅减少计算量。

如果在训练后添加新的数据，是否需要重新训练？通常不需要，但如果有大量新数据导致数据分布变化显著，可能需要重新训练或增量更新簇中心，但 Faiss 本身不支持在线更新簇中心，需要重新训练整个索引。

上面每个簇存储的还是原始的高维向量，这种基础的方式称为 IndexIVFFlat，下面是一个简单的数值实例：

训练聚类（nlist=2）

簇中心（训练后得到）：
centroids = [[0.3, 0.4, 0.5, 0.6], # 簇 0 中心（**虚拟均值**）
[0.7, 0.8, 0.9, 1.0] # 簇 1 中心（虚拟均值）]
倒排列表（向量分配到最近簇）：
inverted_lists = { 0: [向量 0, 向量 2], # 簇 0 包含 ID=0 和 ID=2 这里的 id 就是向量的逻辑 id
1: [向量 1] # 簇 1 包含 ID=1 }

聚类法和乘积量化 IndexIVFPQ

PQ 的核心思想是分而治之，将原始高维向量分割成 m 段子向量，然后分别在每个子向量空间进行独立的预先聚类训练，得到 k 个聚类中心（即 k 个和子向量维度一致的向量），将其编码为码本（索引从 0 到 k）。

然后计算每个子向量和这 k 个聚类中心的相似度（距离），选择最近的聚类中心，用它在上面训练得到的码本索引作为替代。这样便可以得到 m 个聚类中心索引来表征原始的高维向量。

乘积量化索引的本质是把原始高维（d 维）向量用 01bits 值来近似表达，这样每 8 位就可以用一个字节表示，节省存储空间和匹配效率。具体来说，把 d 维分成 m 段（使得每个子向量的维度是 2 到 8 之间的一个数），每一段在预训练中获得 2^k（经验值 8）个聚类中心，称为该段的码书，对新向量编码时，每一子段都寻找对应码书里最近的聚类中心，然后使用其索引并转化为 8 位 01 编码作为近似值。

下面结合具体的例子，来说明上述思想中名词和数字的具体含义，为了让计算可行，使用一个非常小的维度。假设：

向量维度 d = 4

子量化器数量 m = 2

每个子量化器的位数 nbits = 8

m 段是经验值吗？有什么特别含义？

m **不是一个纯经验值，它是一个需要根据原始维度** d **和你的目标来调整的关键超参数。**

数学约束：d 必须能被 m 整除。每个子向量的维度是 d/m。

精度 vs. 速度/内存的权衡：

m **越小**（例如 m=1）：子向量维度 d/m 很大。每个子空间需要非常多的聚类中心（比如 65536 个）才能较好地覆盖高维空间，否则量化误差会很大。**结果：**精度可能较低，码书会很大。

m **越大**（例如 m=d）：子向量维度 d/m=1，变成了标量量化。每个子空间只需要很少的中心（比如 256 个）就能很好地覆盖一维直线。**结果**：压缩率最高，内存最小，但**不同维度之间的相关性被完全忽略**，可能会损失精度。

实践中的选择：通常，m 被设置为 d 的一个分数，使得每个子向量的维度是 2 到 8 之间的一个数。例如，对于 d=128 的向量，一个常见的选择是 m=16 或 m=32。这样每个子向量是 8 维或 4 维。

n bits=8 **的特别含义是什么？**

nbits 决定了每个子量化器有多少个聚类中心。计算公式是：k = 2^n bits。所以 nbits=8 意味着每个子空间会有 2^8 = 256 个聚类中心。**为什么是 8？** 这是一个经典的权衡。256 个中心已经能提供一个较好的近似精度，而最终的编码恰好是 1 个字节（8 bits），**存储效率极高**。你也可以选择 nbits=12（4096 个中心，精度更高，但编码用 1.5 字节），但 8 是一个在精度和效率之间非常好的默认平衡点。

第 1 步：训练阶段 - 创建每个子空间的“码书”

在添加任何数据之前，IndexIVFPQ 需要先进行**训练**。训练的目的是为**每一个子空间**学习一套“密码本”或“字典”，专业术语叫 **码书**。

获取训练数据：从数据集中采样大量向量（例如 100000 个）。

分割向量：将每个训练向量都分成 m=2 段。

独立聚类：将所有向量的**第一段** [v1, v2] 收集起来，用一个 K-Means 算法进行聚类。将所有向量的**第二段** [v3, v4] 收集起来，用另一个 K-Means 算法进行聚类。

训练结果（假设）：

第一段子空间的码书 Codebook1 有了 256 个聚类中心。我们假设前 3 个中心是：C1_0 = [0.1, 0.8] (索引 0)；C1_1 = [0.3, 0.6] (索引 1)；C1_2 = [0.9, 0.0] (索引 2)... (一直到索引 255)

第二段子空间的码书 Codebook2 也有 256 个聚类中心。我们假设前 3 个中心是：C2_0 = [1.0, 0.5] (索引 0)；C2_1 = [0.2, 0.2] (索引 1)；C2_2 = [0.7, 0.9] (索引 2)... (一直到索引 255)

第 2 步：编码阶段 - 一个具体的数字实例

现在，我们要添加一个真实的向量并将其编码。

原始向量：V = [0.32, 0.61, 0.19, 0.23]

分段：Seg1 = [0.32, 0.61] // 前两个维度；Seg2 = [0.19, 0.23] // 后两个维度

为每一段寻找最近的聚类中心：

对于 Seg1 = [0.32, 0.61]，我们计算它与 Codebook1 中所有中心的距离（比如用 L2 距离），找到距离最近的那个。

到 C1_0 [0.1, 0.8] 的距离：$\sqrt{((0.32-0.1)^2 + (0.61-0.8)^2)} \approx \sqrt{(0.0484 + 0.0361)} \approx 0.29$

到 C1_1 [0.3, 0.6] 的距离：$\sqrt{((0.32-0.3)^2 + (0.61-0.6)^2)} \approx \sqrt{(0.0004 + 0.0001)} \approx 0.022$

到 C1_2 [0.9, 0.0] 的距离：$\sqrt{((0.32-0.9)^2 + (0.61-0.0)^2)} \approx \sqrt{(0.3364 + 0.3721)} \approx 0.84$

...（其他中心距离更远）

结论：Seg1 离 C1_1 (索引 1) 最近。

对于 Seg2 = [0.19, 0.23]，我们计算它与 Codebook2 中所有中心的距离。

到 C2_0 [1.0, 0.5] 的距离：很大

到 C2_1 [0.2, 0.2] 的距离：$\sqrt{((0.19-0.2)^2 + (0.23-0.2)^2)} \approx \sqrt{(0.0001 + 0.0009)} \approx 0.032$

到 C2_2 [0.7, 0.9] 的距离：很大

结论：Seg2 离 C2_1 (索引 1) 最近。

生成编码：

原始向量 V 的最终编码就是这两个索引值：(1, 1)

在存储时，这两个索引被紧凑地打包为两个字节：

00000001 (数字 1 的 8 位二进制表示)00000001 (数字 1 的 8 位二进制表示)

这就是 PQ 量化的奇迹所在：一个原始的 4 维浮点数向量（占 4 * 4 = 16 字节）被压缩成了仅仅 2 个字节！ 压缩比为 8:1。对于更真实的维度（如 d=128），节省的内存是巨大的。

第 3 步：搜索时如何计算距离？

搜索的时候同样将查询向量分段，并计算与聚类中心的距离，并记录到查询表中，table[i]，table[j]，一个查询表有 2^k 值，计算查询向量与数据库中存储的任一向量仅需查看原始向量每个子段的索引即可，并将 m 个子段值加起来。

当查询向量 Q = [q1, q2, q3, q4] 来时，如何计算它与库中所有压缩向量的距离？

预处理：将查询向量 Q 也分成两段：Q1 = [q1, q2], Q2 = [q3, q4]。

预先计算距离表：这是一个关键优化！

计算 Q1 到 Codebook1 中 **所有** 256 个中心的距离，得到一个大小为 256 的查找表 Table1。

Table1[0] = distance(Q1, C1_0)； Table1[1] = distance(Q1, C1_1)； Table1[2] = distance(Q1, C1_2)； ...

计算 Q2 到 Codebook2 中 **所有** 256 个中心的距离，得到另一个查找表 Table2。

快速计算近似距离：对于数据库中每个被编码为 (i, j) 的向量（例如我们编码的 (1, 1)），其与查询向量 Q 的近似距离可以通过查表快速得到：

Approximate_Distance = Table1[i] + Table2[j]

对于我们的例子：Distance ≈ Table1[1] + Table2[1]

通过这种查表法，计算一个距离只需要 m 次加法操作，速度极快。

这种组合使得 IndexIVFPQ 在十亿级别的数据集上也能实现毫秒级的搜索，同时将内存占用降低到原始数据的百分之几。

Faiss 索引首先是一个**搜索加速器**，其次才是一个数据存储器。它的主要目标是快速找到相似项，而不是完美地保存原始数据。

HNSW 索引（分层导航小世界图）

核心思想：构建多层图结构，高层为长链接（快速定位），底层为短链接（精细搜索），通过贪婪路由逐步逼近目标 9。
数据结构：
多层图：每层节点代表向量，边表示相似关系。高层稀疏，底层密集。
入口点：顶层随机选择入口节点，逐步向下层搜索
图结构构建（M=2）

分层连接（示例）：
层 2（顶层）：向量 2 → 向量 0（长连接） 层 1（中层）：向量 0 ↔ 向量 2 层 0（底层）：向量 0 ↔ 向量 1 ↔ 向量 2（密集连接）
节点连接关系：
{ 0: {层 0: [1, 2], 层 1: [2]}, 1: {层 0: [0, 2]}, 2: {层 0: [0, 1], 层 1: [0], 层 2: [0]} }

搜索过程

从顶层入口点 向量 2 开始，向下层逐步遍历邻居。

索引类型与特点

索引类型	本质与主要内容	特点与适用场景
faiss.IndexFlatL2(d)	存储所有**原始的向量数据**（float32 数组）。	**精确搜索**，速度慢，内存占用大。适合**小规模数据集**或作为其他索引的量化器 1。
faiss.IndexIVFFlat(quantizer, d, nlist)	1. **聚类中心 (Centroids)**：通过训练得到的 nlist 个聚类中心向量。 2. **倒排列表 (Inverted Lists)**：每个聚类中心对应一个列表，存储属于该簇的**原始向量**及其在原始数据集中的 ID16。	**近似搜索** 1。搜索时先找最近的聚类中心，再在其倒排列表内搜索。需训练，在**速度、精度和内存**之间平衡。
faiss.IndexHNSWFlat(d, M)	1. **聚类中心**：同 IVFFlat。 2. **量化后的向量**：原始向量被分解为 m 个子向量，每个子空间用一套码书 (Codebook) 量化编码（如用 8bits 表示）。**不存储原始向量**。	**近似搜索**。**大幅减少内存占用**，但会**损失精度**。适合**超大规模数据集**。
faiss.IndexPQ(d, M, nbits)	一种**分层图结构**（Hierarchical Navigable Small World）。每一层都是一个小世界图，底层包含所有节点，上层是下层的“快车道”。节点是向量，边代表向量间的相似关系。	**高性能**，高召回率，**无需训练**，但**内存消耗较大**。适合对速度和精度要求高的场景。

为什么需要获取向量的维度 (d)？

计算距离：所有相似度度量（L2、内积、余弦等）的计算都依赖于维度。两个向量必须维度相同才能计算它们之间的距离。Faiss 需要知道 d 来正确执行这些计算。

内存分配与管理：Faiss 需要在内存中为大量向量分配空间。知道 d，它才能准确计算需要多少内存。例如，一个有 100 万个 256 维向量的索引，需要 1,000,000 * 256 * 4 bytes ≈ 1.024 GB 的连续内存（假设 float32，4 字节）。

验证输入数据：当你调用 index.add(vectors) 时，Faiss 会检查 vectors.shape[1] 是否等于索引初始化时指定的 d。这是一种防止错误的保护措施。

构建索引结构：对于 IVF 或 PQ 等复杂索引，聚类中心的数量、量化器的子空间数量等参数都直接与原始向量的维度 d 相关。

原始文本和索引的关系

我们已经知道，索引只负责存储向量保存向量的逻辑 id，即**默认的隐式 ID**

分配模式。Faiss **自动分配**从 0 开始的连续整数，**按** add **顺序分配**。ID **直接对应** 向量被添加到索引中的**顺序**。它完全不知道这些向量代表什么文本、图片或其他内容，检索时返回的也是向量的逻辑 id，因此，需要我们手动建立并维护向量逻辑 ID 与原始文本的对应关系。

自定义 id 与 IndexIDMap

faiss 提供了 IndexIDMap 来支持**自定义逻辑 ID**（（必须是 int64 类型）。这时，数据库主键可能不是简单的 0, 1, 2，而是其他 ID 系统（例如 UUID 或数据库自增 ID）。

基础索引的内部 ID：基础索引（如 IndexFlatL2）存储向量时，会为每个向量分配一个默认的整数 ID，即向量在索引中的**位置索引**，从 0 开始累加（0, 1, 2, ...），这是索引内部自动管理的，用户无法修改。

自定义 ID：用户可以通过 IndexIDMap 为每个向量指定一个自定义 ID（必须是 64 位整数），这个 ID 由用户定义（如业务系统中的唯一标识、哈希值等）。

映射关系：IndexIDMap 会维护一个**内部 ID → 自定义 ID** 的映射表，当用户通过自定义 ID 操作向量（如删除、查询）时，IndexIDMap 会先将自定义 ID 转换为基础索引的内部 ID，再调用基础索引的方法执行操作。

```
import faiss
import numpy as np

d = 768
vectors = np.array([...]) #  你的向量数据

#  假设你的数据库主键是 [10001, 10002, 10003]
custom_ids = np.array([10001, 10002, 10003]).astype('int64')

# 1. 创建一个基础索引
base_index = faiss.IndexFlatL2(d)
# 2. 用基础索引包裹成一个支持自定义 ID 的索引
index = faiss.IndexIDMap(base_index)

# 3. 添加向量时，同时指定自定义 ID
index.add_with_ids(vectors, custom_ids)

#  现在，搜索返回的将是你的自定义 ID [10001, 10002, 10003] 等
distances, indices = index.search(query_vector, k=2)
print("返回的自定义逻辑 ID:", indices[0])
```

文档的增删改与索引变化

对于创建完成的基本索引，如果后续增加，删除，修改文档的话，索引会如何变化呢？

增加 (Add)：索引是按照从 0 开始的顺序编码向量的，因此可以一直累加应对文档的增加，所有索引都支持，但性能和维护方式不同。

```
    # 向已存在的索引添加新文档
# 示例文本库 2（实际需替换为真实数据）
corpus2: List[str] = [
    "The Apollo is a magic human in old ORLAIC myth.",
    "Deep learning is useful in our daily life.",
    "Python is easier to learn than c++.",
    "The Mars is a beautiful planet."
]
# 按照顺序定义 id 和文本的对应关系，注意文本对应的 id 也要增加
start_id=len(seq_id2text)
for i,text in enumerate(corpus2):
    seq_id2text[start_id+i]=text
```

对于聚类的索引如 IndexIVFFlat，它先通过聚类将空间划分成 `nlist` 个单元（簇），每个向量被分配到最近的簇中。**增加文档后，**为新向量计算其最近的簇中心，然后将它添加到对应簇的倒排列表中，索引大小增加。大量增加文档后需要重新训练。

删除 (Remove)：基础索引一般是不能修改的，因此当删除一个文档之后，向量的逻辑 id 就不是连续的了，会导致搜索返回的 id 对应不上实际的文本。因此基础索引不支持删除。只有使用了 `IndexIDMap` 或 `IndexIDMap2` 包装的索引才能有效地按 ID 删除。

```
# 3. **删除文档**：删除 ID 为 30 的向量

index.remove_ids(np.array([1001]).astype('int64')) # 关键：按 ID 删除

print("删除后 ID 列表:", index.id_map.array) # [10, 20, 50, 40] (顺序可能变，30 被移除)
```

它并不真的从基础索引的物理存储中移除数据（这很昂贵），而是：在反向映射表中将对应 ID **标记为已删除**。后续搜索时，**跳过**那些被标记的向量。所以，删除后索引的物理大小可能没变，但 `ntotal` 会减少，有效数据量减少了

修改 (Update)：FAISS 没有直接的“修改”操作。你必须先“删除”旧的向量，再“添加”新的向量。这本质上是“删”+“增”的组合。

```
# 4. **修改文档**：这本质上是“删除” + “添加”

# 假设要修改 ID 为 20 的向量

new_vector_for_20 = np.random.random((1, dimension)).astype('float32')

# 4.1 先删除旧的

index.remove_ids(np.array([20]).astype('int64'))

# 4.2 再添加新的（使用相同的 ID）

index.add_with_ids(new_vector_for_20, np.array([20]).astype('int64'))
```

对于需要频繁增删改的场景，最佳实践是：

> 使用 `IndexIDMap2` 包装你的基础索引（如 `IndexFlatL2` 或 `IndexIVF...`）。
>
> 通过 `add_with_ids` 和 `remove_ids` 方法来管理向量。
>
> 对于 `IVF` 索引，要有定期重新训练的心理准备和流程设计。
>
> 如果数据变动非常剧烈，另一种策略是**定期批量重建整个索引**，这有时比频繁增删改更高效。

Faiss 数据的类型和变化流动

以文本为例：
分割后的文本块——向量数组——索引——文本 id 对应词典

FAISS 的 search 方法支持**批量查询**（一次传入多个查询向量），因此返回的 distances 和 indices 是二维数组：

- 第一维对应查询向量的索引（如 `distances[0]`表示第 1 个查询向量的结果）；
- 第二维对应每个查询返回的 k 个结果（按相似度排序，第 0 个最相似）。

例如，当 k=2 且只有 1 个查询向量时：

- `distances` 的形状为 `(1, 2)` → `distances[0]`是长度为 2 的列表（存储 2 个距离值）；
- `indices` 的形状为 `(1, 2)` → `indices[0]`是长度为 2 的列表（存储 2 个向量索引）。

基于 LangChain 集成的 FAISS

LangChain 的 FAISS 封装是“文档驱动”的，通过集成嵌入生成、文档管理、索引操作，大幅降低了构建基于向量的文档检索系统的门槛，适合快速开发 LLM 应用。而原生 FAISS 是“向量驱动”的，专注于高效的向量索引与计算，适合需要深度定制向量处理逻辑的场景（如大规模向量优化、自定义索引策略等）。

也就是说，langchain 框架主要是处理文档，而 faiss 只是调用的一个工具，这也就意味着 faiss 对向量索引的优化在 langchain 框架下不能很好地使用。

LangChain 提供了一层优雅的抽象，专门用于处理向量存储中 **“向量”、“ID”和“原始文本（及元数据）”** 之间繁琐但至关重要的映射关系。

其核心设计哲学是：**开发者只需关心文档（Document）本身，而无需手动维护 ID 映射。LangChain 会自动处理这些细节。**

LangChain 通过以下两个核心组件协同工作，建立并维护 ID 与文本的映射：

向量存储 (Vectorstore)：负责存储**向量数据**以及**向量与 ID 的映射**（例如通过 IndexIDMap），并执行相似性搜索。它返回的是与查询最相似的向量的 **ID**。

文档存储 (Docstore)：负责存储 **ID 到完整** Document **对象** 的映射。Document 对象包含了 page_content (原始文本) 和 metadata (元数据)。

核心概念定义 Vectorstore (向量存储)：

定义：一个用于存储、检索和管理**向量嵌入**（embeddings）的抽象层。（是一个抽象类吗？）

在 LangChain 中的角色：它是一个**接口**，定义了所有向量数据库（如 FAISS, Chroma, Pinecone）都需要实现的一系列标准方法（如 add_documents, similarity_search）。

FAISS 类是 LangChain 对原生 FAISS 库的一个包装器，实现了 Vectorstore 接口。其通过属性和方法重新实现了原生 faiss 的索引结构，索引添加向量，向量 id 和文本的对应关系。

Vectorstore 创建方式与基本属性方法

Vectorstore (基于 FAISS)

最常用的方法是从文档直接创建，LangChain 会自动处理所有底层细节（文本嵌入、索引创建、ID 生成、映射维护）。

```
from langchain_community.vectorstores import FAISS
from langchain_core.documents import Document
# 准备文档
documents = [
    Document(page_content="LangChain is a framework for LLM applications.",
metadata={"source": "doc1"}),])
embeddings = OpenAIEmbeddings()
# 创建 Vectorstore - 最常用的方式
vectorstore = FAISS.from_documents(documents, embeddings)
# 也可以从已存在的索引和文档存储加载#
vectorstore = FAISS(embedding_function=embeddings, index=loaded_index,
docstore=loaded_docstore, index_to_docstore_id=loaded_mapping)
```

基本属性：

embedding_function: 用于生成向量嵌入的模型。

index: 底层的 FAISS 索引对象（如 IndexFlatL2, IndexIDMap）。

docstore: 与之关联的文档存储对象。

index_to_docstore_id: 一个字典，映射 **FAISS 索引内部 ID** 到 **Docstore 中的文档 ID**。

核心方法：

from_documents(documents, embedding, **kwargs): **类方法**。创建索引、生成嵌入、添加文档、建立所有映射。

from_texts(texts, embedding, metadatas=None, **kwargs): **类方法**。与 from_documents 类似，但直接接收文本列表。

add_documents(documents, **kwargs): **实例方法**。向已存在的索引中添加新文档。

similarity_search(query, k=4, **kwargs): **实例方法**。执行相似性搜索，返回一个 Document 对象的列表。

similarity_search_with_score(query, k=4, **kwargs): **实例方法**。返回文档及其相似度分数。

save_local(folder_path, index_name="index"): 将索引和文档存储保存到磁盘。

load_local(folder_path, embeddings, index_name="index", **kwargs): **类方法**。从磁盘加载。

FAISS.from_documents

1. FAISS.from_documents 内部原理

步骤 1: 文本分割（如果必要）

虽然传入的是一个 Document 列表，但每个 Document 可能包含较长的文本。LangChain 的文本分割器（如果指定）会将每个文档分割成更小的块（chunks）。

步骤 2: 向量化

使用传入的 embedding_model（一个 Embedding 模型适配器）将每个文本块转化为向量。这个适配器会调用底层的嵌入模型（例如通义千问的嵌入模型）来生成向量。

步骤 3: 构建 Faiss 索引 index

根据指定的参数（如 normalize_L2 和 distance_strategy）创建 Faiss 索引 index。

- normalize_L2=True：表示在添加向量之前会对向量进行 L2 归一化。归一化后的向量点积等于余弦相似度。

- distance_strategy="METRIC_INNER_PRODUCT"：设置 Faiss 使用内积作为相似度度量。因为归一化后的内积等于余弦相似度，所以这样设置是为了进行余弦相似度搜索。

步骤 4: 添加向量和元数据

- 将向量添加到 Faiss 索引中。

- 同时，将每个文本块的元数据（来自 Document 的 metadata）存储在一个独立的结构中（通常是列表或字典），以便在搜索时能够返回对应的元数据。

步骤 5: 返回 FAISS 向量存储对象

- 返回一个 FAISS 对象，该对象包含：

- Faiss 索引（用于向量搜索）

- 存储的元数据（用于返回搜索结果时的额外信息）

- 嵌入模型（用于在添加新文档时进行向量化）

```
# langchain/vectorstores/faiss.py
class FAISS(VectorStore):
    def __init__(
        self,
        embedding_function: Callable,
        index: Any,
        docstore: Docstore,
        index_to_docstore_id: Dict[int, str],
        normalize_L2: bool = False,
    ):
        # 存储核心组件
        self.embedding_function = embedding_function
        self.index = index
        self.docstore = docstore
        self.index_to_docstore_id = index_to_docstore_id

    @classmethod
    def from_documents(
```

```
            cls,
            documents: List[Document],
            embedding: Embeddings,
            **kwargs,
        ) -> FAISS:
            # 1. 提取文本内容
            texts = [doc.page_content for doc in documents]
            # 2. 调用 from_texts 核心方法处理文本
            return cls.from_texts(texts, embedding, metadatas=[doc.metadata for doc in documents], **kwargs)

        @classmethod
        def from_texts(
            cls,
            texts: List[str],
            embedding: Embeddings,
            metadatas: Optional[List[dict]] = None,
            **kwargs,
        ) -> FAISS:
            # 3. 生成嵌入向量
            embeddings = embedding.embed_documents(texts)
            # 4. 创建 Faiss 索引
            dim = len(embeddings[0])
            index = faiss.IndexFlatIP(dim)
            # 5. 归一化处理
            if kwargs.get("normalize_L2", False):
                faiss.normalize_L2(np.array(embeddings))
                index = faiss.IndexIDMap(index)

            # 6. 添加向量到索引
            index.add(np.array(embeddings, dtype=np.float32))
            # 7. 构建文档存储
            docstore = InMemoryDocstore()
            index_to_id = {}
            for idx, text in enumerate(texts):    # idx 是文本块的索引顺序
                metadata = metadatas[idx] if metadatas else {}
                doc_id = str(uuid.uuid4())      #  使用 uuid 方法生成文档 id
                docstore.add({doc_id:                Document(page_content=text, metadata=metadata)})
                index_to_id[idx] = doc_id
```

事实上索引内部的 id 并没有改变，只是额外增加了一层映射，将内部 id 和自定义的 id 如 doc-id 绑定起来，然后再利用 doc-id 和文本建立的映射关系返回对应文本。

```
        # 8. 返回向量存储对象
        return cls(embedding, index, docstore, index_to_id, **kwargs)
```

从上面的代码可以看出来，langchain 下的 from_documents 只是封装了单独使用 faiss 的步骤，其基本原理是一致的。

add_embeddings 方法

原理：将文本向量和元数据添加到 FAISS 索引和文档存储器中。

```
# 源码路径：langchain/vectorstores/faiss.py
def add_embeddings(
    self,
    text_embeddings: List[Tuple[str, List[float]]],
    metadatas: Optional[List[dict]] = None,
) -> None:
    embeddings = np.array([emb for _, emb in text_embeddings], dtype=np.float32)
    self.index.add(embeddings)  # FAISS 原生添加操作

    # LangChain 扩展：存储文档内容
    texts = [text for text, _ in text_embeddings]
    for idx, text in enumerate(texts):
        metadata = metadatas[idx] if metadatas else {}
        doc = Document(page_content=text, metadata=metadata)
        doc_id = str(uuid.uuid4())
        self.docstore.add({doc_id: doc})
        self.index_to_docstore_id[idx] = doc_id
```

save_local 方法

原理：保存索引到磁盘（包含 FAISS 索引 + 文档元数据）。

```
def save_local(self, folder_path: str) -> None:

    # 保存 FAISS 索引
    faiss.write_index(self.index, f"{folder_path}/index.faiss")
    # 保存 LangChain 特有数据
    with open(f"{folder_path}/index.pkl", "wb") as f:
        pickle.dump((self.docstore, self.index_to_docstore_id), f)
```

load_local 方法

原理：从磁盘加载索引及关联文档数据。

```
@classmethoddef load_local(
    cls,
```

```
        folder_path: str,
        embeddings: Embeddings) -> FAISS:
        # 加载 FAISS 索引
        index = faiss.read_index(f"{folder_path}/index.faiss")
        # 加载 LangChain 特有数据
        with open(f"{folder_path}/index.pkl", "rb") as f:
            docstore, index_to_docstore_id = pickle.load(f)
        return cls(embeddings, index, docstore, index_to_docstore_id)
```

similarity_search

搜索请求入口：用户调用 vectorstore.similarity_search("what is FAISS?")。

查询向量化：vectorstore 使用其 embedding_function 将查询文本转换为一个向量 query_vector。

向量相似性搜索：vectorstore 调用 self.index.search(query_vector, k=4)。**底层的 FAISS 索引返回一个包含内部 ID 和距离的数组**，例如 ([0, 2, 5], [0.1, 0.2, 0.3])。

ID 转换与文档检索：

vectorstore 查看 self.index_to_docstore_id 映射字典，将内部 ID [0, 2, 5] 转换为 Docstore 中的 ID ['uuid-123', 'uuid-456', 'uuid-789']。

然后，它调用 self.docstore.search('uuid-123')，self.docstore.search('uuid-456')...（实际上是一次性批量获取）。

返回结果：docstore 返回对应的 Document 对象。vectorstore 将这些对象收集到一个列表中并返回给用户。用户最终得到的是包含原始文本和元数据的文档，完全无需感知底层复杂的 ID 映射和向量处理。

Docstore (文档存储)探究：

在原生的 faiss 实现中，我们需要手动维护一个向量 id 到原始文本的映射，而且原始文本和向量是独立存在的，而 langchain 框架则使用 vectorstore 的一个属性（本质是字典）来统一处理存储原始文本和元数据，这就是 docstore。

在 LangChain 中的角色：它是一个简单的存储抽象（也是抽象类吗？），通常基于字典实现（如 InMemoryDocstore），负责维护 ID 到 Document 对象（包含文本和元数据）的字典。

通常你不需要直接创建它。它在 FAISS.from_documents() 过程中被自动创建和关联。在底层，它通常是一个 InMemoryDocstore 实例。

本质上，LangChain 内部是这样做的：

```
from langchain_community.docstore.in_memory import InMemoryDocstore

docstore = InMemoryDocstore({
    "uuid-1234": Document(page_content="...", metadata={...}),
    "uuid-5678": Document(page_content="...", metadata={...}),})
```

在 LangChain 中，向量 ID、索引（向量存储的位置）与文本（原始文档）的映射关系是通过**三层结构**实现的，核心目的是确保“向量检索结果”能准确关联到“原始文档内容”。

这三层结构分别是：**FAISS 向量索引**（存储向量）、**index_to_docstore_id 映射表**（向量索引→文档 ID）、**DocStore**（文档 ID→原始文本）。

- 每个向量在 FAISS 索引中都有一个唯一的**位置索引**（int 类型，如 0、1、2...代表第 0 个向量、第 1 个向量）；
- 这个位置索引通过 index_to_docstore_id（字典，key 为位置，value 为文档 ID）映射到唯一的**文档 ID**（如 "doc-1"、"uuid-xxx"）；
- 文档 ID 再通过 DocStore 映射到包含原始文本的 **Document 对象**（字典，key 为文档 ID，value 为 Document 对象，包含原始文本）。

LangChain 的 FAISS VectorStore 的 index_to_docstore_id 字典映射和 indexIDMap 的核心差异如下：

实现方式	原生 FAISS 的 indexIDMap	LangChain 的 index_to_docstore_id
ID 类型	仅支持 64 位整数（int64）	支持任意哈希 able 类型（如字符串、UUID）
映射方向	向量→自定义 ID（通过 add_with_ids 关联）	向量位置索引→文档 ID（字典映射）
依赖对象	包装在 FAISS 索引内部，与索引绑定	独立于 FAISS 索引的 Python 字典
用途	向量与自定义 ID 的直接关联，支持 ID-based 操作	向量位置与文档 ID 的关联，用于对接 DocStore
动态更新	支持通过 remove_ids 删除向量（基于自定义 ID）	删除向量需同步更新字典，操作更繁琐

文档的增删改

LangChain 中文档的本质是 Document 对象（包含 page_content 文本内容、metadata 元数据和 id 唯一标识）。操作流程如下：

- **新增**：生成文档向量 → 存入 VectorStore → 原始文档存入 DocStore → 更新映射关系；

- **删除**：从 VectorStore 中删除对应向量 → 从 DocStore 中删除原始文档 → 更新映射关系；
- **修改**：无直接修改接口，需通过“删除旧文档 + 新增修改后文档”实现（因向量由文本生成，文本修改后向量必变）。

文档新增（Add）

新增文档是最基础的操作，LangChain 的 VectorStore 提供了 add_documents 方法，自动完成向量生成、存储及映射同步。

```
from langchain.vectorstores import FAISS
from langchain.embeddings import OpenAIEmbeddings
from langchain.docstore.document import Document
# 初始化嵌入模型和空的 FAISS 向量库
embeddings = OpenAIEmbeddings()
# 创建空向量库(需手动初始化 DocStore 和映射,实际可直接用 from_documents 创建)
vs = FAISS.from_documents([], embeddings)
# 1. 准备新增文档（可指定 ID，也可自动生成）
new_docs = [
    Document(
        page_content="LangChain 支持多种向量存储后端，如 FAISS",
        metadata={"source": "doc1"},
        id="doc-1"  # 自定义文档 ID
    ),
    Document(
        page_content="RAG 是检索增强生成的缩写,核心是结合检索和 LLM 生成",
        metadata={"source": "doc2"},
        id="doc-2"
    )]
# 2. 新增文档（自动处理向量生成、存储和映射）
vs.add_documents(new_docs)
# 3. 验证新增结果
print(f"向量库总数: {db.index.ntotal}")  # 输出：2（新增 2 个向量）
print(f"DocStore 中的文档 ID: {list(vs.docstore.docs.keys())}")  # 输出：['doc-1', 'doc-2']
print(f"向量索引→文档 ID 映射: {db.index_to_docstore_id}")  # 输出:{0: 'doc-1', 1: 'doc-2'}
# 4. 检索验证（能找到新增文档）
query = "什么是 RAG? "
results = db.similarity_search(query, k=1)
print(results[0].page_content)  # 输出："RAG 是检索增强生成的缩写..."
```

内部实现逻辑

add_documents 方法的核心步骤（简化）：

1. 对输入的 Document 对象，若未指定 id 则自动生成（如 UUID）；
2. 调用嵌入模型（embedding_function）将 page_content 转换为向量；
3. 将向量添加到 FAISS 索引（index.add(vectors)），此时向量在索引中的位置为 [当前 ntotal，当前 ntotal+1，...]；
4. 将文档存入 DocStore（docstore.add(docs)）；
5. 更新 index_to_docstore_id 映射：{新向量位置：文档 ID，...}。

文档删除（Delete）

LangChain 未直接提供 delete_documents 方法，需通过 “查找文档 ID 对应的向量索引→删除向量→删除 DocStore 文档→更新映射” 手动实现。

```
# 承接上文的 vs 对象（已包含 doc-1 和 doc-2）
# 1. 确定要删除的文档 ID
doc_id_to_delete = "doc-1"
# 2. 查找文档 ID 对应的向量索引（从 index_to_docstore_id 中反向查找）
index_to_delete = None
for idx, doc_id in vs.index_to_docstore_id.items():
    if doc_id == doc_id_to_delete:
        index_to_delete = idx
        Break
    if index_to_delete is None:
        raise ValueError(f"文档 ID {doc_id_to_delete} 不存在")
# 3. 从 FAISS 索引中删除向量（需先转换为索引列表）# 注意：FAISS 的 remove_ids 接收的是内部索引（0,1,2...），而非自定义 ID
vs.index.remove_ids(np.array([index_to_delete], dtype=np.int64))
# 4. 从 DocStore 中删除文档
vs.docstore.delete([doc_id_to_delete])
# 5. 更新 index_to_docstore_id 映射（删除对应键值对，并重新对齐后续索引）
# 原映射：{0: 'doc-1', 1: 'doc-2'} → 删除 0 后，需将 1 的索引改为 0
new_index_to_docstore_id = {}
for idx, doc_id in vs.index_to_docstore_id.items():
    if idx != index_to_delete:
        # 若索引大于被删除的索引，需减 1（因 FAISS 删除后后续向量索引自动前移）
        new_idx = idx - 1
    if idx > index_to_delete else idx
        new_index_to_docstore_id[new_idx] = doc_id
vs.index_to_docstore_id = new_index_to_docstore_id
# 6. 验证删除结果
print(f"删除后向量库总数: {vs.index.ntotal}")  # 输出：1
print(f"DocStore 剩余文档 ID: {list(vs.docstore.docs.keys())}")  # 输出：['doc-2']
```

```
print(f"更新后映射: {vs.index_to_docstore_id}") # 输出：{0: 'doc-2'}
# 7. 检索验证（无法找到被删除的文档）
query = "LangChain 支持哪些向量存储？"
results = vs.similarity_search(query, k=1)
print(results) # 输出：[]（因 doc-1 已被删除）
```

- FAISS 索引删除向量后，**后续向量的内部索引会自动前移**（如删除索引 0 后，原索引 1 变为新索引 0），因此必须同步更新 index_to_docstore_id 的键（索引值）；
- 若使用 IndexIDMap 包装的 FAISS 索引（支持自定义 ID），删除逻辑可简化（直接通过自定义 ID 删除向量），但 LangChain 的 FAISS 类默认不使用 IndexIDMap，需手动改造。

文档修改（Update）

由于文档向量由文本内容生成，修改文本后向量必然变化，因此 LangChain 中 “修改” 需通过 “删除旧文档 + 新增修改后文档” 实现。

```
# 承接上文的 vs 对象（当前包含 doc-2）
# 1. 定义要修改的文档 ID 和新内容
old_doc_id = "doc-2"
new_doc = Document(
    page_content="RAG（检索增强生成）是一种结合信息检索和大语言模型的技术，能提升生成内容的准确性", # 修改后的文本
    metadata={"source": "doc2-updated"}, # 修改元数据
    id=old_doc_id # 保留原 ID（或换新 ID））
# 2. 先删除旧文档（复用删除逻辑）# 查找旧文档索引
index_to_delete = Nonefor idx, doc_id in
vs.index_to_docstore_id.items():
    if doc_id == old_doc_id:
        index_to_delete = idx
        break# 删除向量
vs.index.remove_ids(np.array([index_to_delete], dtype=np.int64))# 删除 DocStore 文档
vs.docstore.delete([old_doc_id])# 更新映射
new_index_map = {idx: doc_id for idx, doc_id in
vs.index_to_docstore_id.items() if idx != index_to_delete}
vs.index_to_docstore_id = new_index_map
# 3. 新增修改后的文档
vs.add_documents([new_doc])
# 4. 验证修改结果
print(f"修改后向量库总数: {vs.index.ntotal}") # 输出：1（删除 1 个+新增 1 个）
```

```
print(f"DocStore 中的文档内容:
{vs.docstore.search([old_doc_id])[0].page_content}") # 输出修改后的文本
# 5. 检索验证（匹配修改后的内容）
query = "RAG 的作用是什么？"
results = vs.similarity_search(query, k=1)
print(results[0].page_content) # 输出："RAG（检索增强生成）是一种结合..."
```

- 若希望保留原文档 ID，新增时使用原 ID 即可；若需换新 ID，直接指定新 ID 即可；
- 本质是通过“删除旧向量 + 生成新向量 + 新增新向量”实现修改，确保向量与文本内容的一致性。

与原生 FAISS 的对比

特性	LangChain FAISS Vectorstore	原生 FAISS
抽象级别	**高级抽象**。提供“一站式”解决方案，专注于 LLM 应用集成。	**低级库**。专注于核心的向量相似性搜索算法和数据结构。
文档管理	**内置**。自动处理文档存储、ID 生成、文本到向量的转换以及映射。	**无**。需要自己实现：文本嵌入、ID 管理、元数据存储、ID 与向量/文本的映射。
易用性	**非常简单**。几行代码即可完成从文档到检索的完整流程。from_documents 和 similarity_search 是核心。	**相对复杂**。你需要手动处理许多细节，如初始化索引、管理数据类型、处理 ID 等。
功能焦点	**检索增强生成（RAG）**。与 LangChain 的链（Chains）、代理（Agents）无缝集成，返回可直接使用的文档上下文。	**纯向量相似性搜索**。只返回向量的索引和距离，不关心向量代表什么。
扩展性	**通过 Vectorstore 接口**。可以轻松更换后端（如从 FAISS 切换到 Chroma 或 Pinecone），代码改动最小。	**依赖自身**。功能扩展需要基于 FAISS 的 API 自己编码实现。
性能	由于增加了抽象层和额外的映射查找，**有轻微开销**。但对于大多数 RAG 应用来说微不足道。	**极致性能**。直接操作底层，没有任何额外开销。适用于对延迟极其敏感的纯向量搜索场景。
ID 映射	需外部维护向量 ID↔文档 ID 映射	内置 index_to_docstore_id 字典

总而言之，LangChain 的 FAISS Vectorstore 不是一个替代品，而是一个基于原生 FAISS 构建的、针对特定领域（LLM 应用）的、高度集成化的解决方案。它通过引入 Docstore 和一套自动化流程，将原生 FAISS 从一个单纯的向量计

算引擎，变成了一个完整的“文档检索系统”。

单独加载索引和缓存池维护索引的异同点

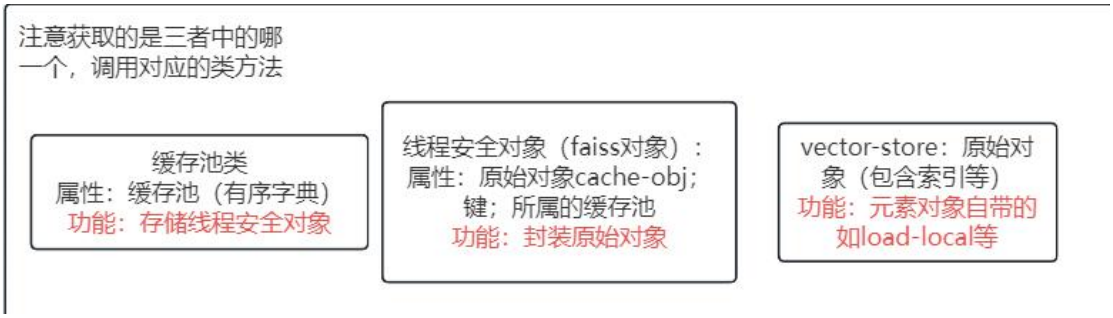

1. Faiss 索引单独加载

静态加载机制
通过 faiss.read_index("index_file.index")直接读取预构建的二进制索引文件，索引数据（向量+结构）完整加载到内存。适用于数据更新频率低（如日级更新）的场景。

无动态管理
索引加载后不支持增量添加或删除向量（除 IndexIVF 系列），需全量重建索引。例如删除向量需调用 index.remove_ids()，时间复杂度 O(n)。

资源独占
每次加载生成独立内存副本，1GB 索引加载 N 次即消耗 N 倍内存 7。

2. 缓存池加载调用（以 CachePool 为例）

动态资源管理
使用 OrderedDict 存储索引对象，通过 LRU 策略自动淘汰旧索引（如 _cache.popitem(last=False)），结合 threading.RLock()实现线程安全。

两级锁定机制

池级锁：self.atomic = threading.RLock()保护缓存字典结构；

对象级锁：ThreadSafeObject 内部锁控制单个索引的并发访问。

智能加载路由
load_kb_embeddings()根据模型类型选择本地或在线嵌入服务（如 EmbeddingsFunAdapter），实现资源按需加载 2。

二、操作流程对比

Faiss 单独加载流程

```
import faiss
# 1. 从磁盘加载索引
index = faiss.read_index("index_file.index")  # 加载后索引完整驻留内存# 2. 执行搜索（无并发控制）
distances, indices = index.search(query_vectors, k)  # 直接调用，线程不安全# 3. 删除向量（仅 IVF 索引支持）
index.remove_ids(np.array([id1, id2]))  # 触发全量索引重组，耗时 O(n)
```

缓存池调用流程

```
# 1. 从缓存池获取索引（自动加池级锁）
with cache_pool.atomic:  # RLock 保护
    obj = cache_pool.get("model_v1")  # LRU 策略移动条目
# 2. 获取对象锁并操作
with obj.acquire(owner="worker1"):
#  对象级锁
    results = obj.search(query_vectors, k)
# 3. 动态更新缓存
cache_pool.set("model_v2", new_index)
#  触发淘汰检查（若超限移除最旧索引）
```


三、适用场景推荐

中小规模静态数据 → Faiss 单独加载（简单高效）；

大规模高并发服务 → 缓存池 + Milvus/Faiss GPU（生产级运维）

Faiss 单独加载适用场景

离线批处理：如每日更新推荐模型，全量索引重建 4；

资源受限环境：嵌入式设备等无法运行缓存服务的场景；

精确检索实验：需 100%召回率的算法验证 8。

缓存池加载适用场景

高并发在线服务：AI 推荐系统、实时图像检索；

多租户资源隔离：不同业务线共享 GPU 资源池；

动态索引管理：频繁切换模型（如 A/B 测试）6。